

引用格式: 闫禹树, 许川佩, 杨斌, 等. TSA-BSGMM: 基于时间和空间注意力机制的运动目标检测算法[J]. 微电子学与计算机, 2026, 43(5): 17-27.

YAN Y S, XU C P, YANG B, et al. TSA-BSGMM: A motion target detection algorithm based on time and space attention mechanisms[J]. Microelectronics & Computer, 2026, 43(5): 17-27.

DOI: 10.19304/J.ISSN1000-7180.2025.0150

TSA-BSGMM: 基于时间和空间注意力机制的 运动目标检测算法

闫禹树¹, 许川佩¹, 杨斌², 危远荣¹

(1 桂林电子科技大学 电子工程与自动化学院, 广西 桂林 541004;

2 北京航天微系统与信息技术研究所, 北京 100094)

摘 要: 运动目标检测是计算机视觉中的一个重要研究方向, 旨在从视频或连续图像序列中识别运动物体。然而, 传统运动目标检测算法在动态背景、光照变化等复杂环境下检测精度较低。为此, 本文提出一种基于时空注意力机制的高斯混合建模背景消除法(Gaussian Mixture Model-based Background Subtraction with Temporal and Spatial Attention Mechanisms, TSA-BSGMM)。该算法以传统高斯混合建模背景消除法为基础, 在背景建模阶段引入空间注意力机制以提升背景模型的准确性; 在背景与前景分割阶段采用形态学处理来抑制噪声并增强目标形状; 在背景模型更新阶段引入多级时序注意力机制, 使模型能够快速适应如光照突变等环境变化。实验结果表明, TSA-BSGMM 在自建数据集上取得了 87.92% 的准确率, 并且在发生光照突变后的 13 帧内, 其检测准确率能够恢复至突变前水平的 90% 以上, 综合性能显著优于现有主流运动目标检测算法。

关键词: 运动目标检测; 背景消除法; 空间注意力机制; 多级时序注意力机制; 计算机视觉

中图分类号: TP391

文献标识码: A

文章编号: 1000-7180(2026)05-0017-11

TSA-BSGMM: A motion target detection algorithm based on time and space attention mechanisms

YAN Yushu¹, XU Chuanpei¹, YANG Bin², WEI Yuanrong¹

(1 School of Electronic Engineering and Automation, Guilin University of Electronic Technology, Guilin 541004, China;

2 Beijing Institute of Aerospace Micro-systems and Information Technology, Beijing 100094, China)

Abstract: Motion object detection is a critical research area in computer vision, aiming to identify moving objects from videos or continuous image sequences. However, traditional motion object detection algorithms often suffer from low detection accuracy in complex environments, such as dynamic backgrounds and varying illumination conditions. To address this limitation, this paper proposes a Gaussian Mixture Model-based Background Subtraction method with Temporal and Spatial Attention mechanisms (TSA-BSGMM). Built upon the traditional Gaussian mixture model-based background subtraction framework, the proposed method incorporates a spatial attention mechanism in the background modeling phase to enhance model precision. During the background-foreground segmentation stage, morphological processing is applied to suppress noise and reinforce object shapes. Furthermore, a multi-level temporal attention mechanism is introduced in the background update phase, enabling the model to rapidly adapt to abrupt environmental changes, such as sudden illumination variations. Experimental results show that the TSA-BSGMM achieves an accuracy of 87.92% on a self-built dataset.

Moreover, within 13 frames after a sudden change in illumination, the detection accuracy recovers to over 90% of the pre-change level, demonstrating significant superiority over existing state-of-the-art motion object detection methods.

Key words: motion target detection; background subtraction method; spatial attention mechanism; temporal attention mechanism; computer vision

1 引言

运动目标检测(Motion Object Detection)是计算机视觉中的一个重要研究方向,旨在从视频或连续图像序列中识别出所有处于运动状态的物体。与传统的目标检测方法不同,运动目标检测无需事先了解目标的具体类别,只要目标存在运动即可被检测到。

运动目标检测技术具有广泛的应用前景,涵盖了安防监控、智能交通、机器人导航、自动驾驶、医疗影像处理等多个领域。在安防监控领域,运动目标检测有助于实时发现潜在安全隐患;在智能交通领域,通过动态监控和分析交通流量及异常情况,从而优化交通管理;在自动驾驶和机器人导航领域,运动目标检测则可以提供精准的环境感知能力,从而减少碰撞风险,提高系统安全性与自主性。因此,运动目标检测不仅是一个技术挑战,更是推动各行业智能化发展的关键技术^[1-4]。

近年来,在运动目标检测领域涌现了许多创新方法,大致可分为3类:帧间差分法、背景消除法和光流法^[5-7]。

帧间差分法是一种简单且快速的运动目标检测方法。它通过计算相邻帧之间像素的差异来检测运动区域。通常使用相邻帧之间的像素差分,然后对差分结果进行二值化以得到运动区域。该方法的优点是计算量小,但缺点是噪声多、对缓慢运动的物体不敏感、容易受到背景变化的影响。该方法适合静态场景中的目标检测,即背景基本不变、且运动物体明显的情况^[8]。

背景减除方法通过将当前帧与事先建好的背景模型进行对比,来区分前景和背景。该方法的优点是具有较高的精度,对渐变背景有很好的适应性,但缺点是计算量较大,适合对计算资源要求较高的场景。因此该方法适用于背景变化较小但包含一些周期性变化的场景(如树叶的轻微摆动或光线的变化)。其中背景模型的建立方法可以进一步细分为几种方法:基础背景建模、统计背景建模、模糊背景建模、背景聚类、神经网络背景建模、背景波动建模和背景估计^[9-10]。

<https://mc.spacejournal.cn>

光流法通过计算图像上各像素的光流场来检测运动目标,该方法通过生成每个像素点的运动向量场,从而计算物体运动方向和速度。常用的光流计算方法包括 Lucas-Kanade 法和 Horn-Schunck 法等。该方法的优点是能够较为准确地检测目标的运动方向和速度,但缺点是对计算资源要求极高,且对噪声敏感,在缺乏专用硬件时难以支持全屏实时视频流的应用。因此该方法适用于需要得到运动目标速度与方向的复杂场景^[11-13]。

除了这些传统方法外,还有许多基于传统方法的改进策略。Tah 等^[14]提出了结合卡尔曼滤波器和背景消除法的方法,通过分解运动物体为不同子区域并探讨其之间的关系,结合背景消除法进行目标检测,在 Wall eur 和 2R 数据集上获得了较为良好的检测结果,平均准确率达到 0.639 6%。Ali 和 Mohammed^[15]提出了一种改进的背景消除法,将 K-means 聚类 and 直方图结合进行背景建模,有效去除动态背景和阴影,提升了检测的准确性。Fernández-Rodríguez 等^[16]则将光流法与 nnU-Net 分割框架相结合,通过融合图像与运动特征提升腹腔镜手术器械的分割精度与鲁棒性,为手术器械定位、动作分析及术中安全评估提供可靠依据。

此外,汤旻安和王晨雨^[17]则提出一种改进的 ViBe 算法,结合哈希算法和图像二维信息熵,解决了传统 ViBe 算法在静态背景下目标检测效果差和鬼影现象的问题。通过改进后的方法,在静态场景下可有效提升检测精度。而 Jeevith 等^[18]提出了一种创新的混合模型,将鲁棒主成分分析(Robust Principal Component Analysis, RPCA)与局部二值模式(Local Binary Pattern, LBP)技术结合,并采用 Grassmann 平均法进行背景减除。Grassmann 平均法能有效减少大范围异常值, RPCA 则提取稀疏矩阵(前景信息)和低秩矩阵(背景信息),而 LBP 用于特征提取。这些改进方法有效提升了在复杂背景和动态变化下的目标检测性能。Mohant 和 Rup^[19]提出了改进的时空局部二值模式(Spatio-Temporal Local Binary Pattern, STLBP)技术,从视频帧中提取空间纹理特征与时间运动特征,并提出一种自适应背景建模公式,结合学习率(α_b)和阈值(T_p)来优化背景建模

过程。

然而, 运动目标检测在实际应用中面临诸多局限。例如, 在动态背景下稳定性较差, 无法有效应对复杂的环境变化(如树叶晃动等); 对于突发变化(如突如其来的光照变化)反应较慢; 同时, 背景噪声往往导致误判和错误识别。

为解决以上问题, 本文提出一种改进的高斯混合建模背景消除法 TSA-BSGMM(基于时序注意力和空间注意力机制的高斯混合背景消除法)。该算法基于传统的高斯混合背景建模方法, 在背景建模阶段引入了空间注意力机制, 从而提升背景模型在动态背景下的稳定性; 在前景与背景分割阶段, 引入形态学处理, 有效减少了背景噪声引发的误判; 在背景模型更新阶段, 采用多级时序注意力机制, 有效解决了模型在光照突变等突发情况下反应迟钝的问题。

通过在本文构建的数据集上进行实验验证, 在准确率上达到了 88%, 并能够在 13 帧内适应光照突变的变化。相比基线算法在 70% 的准确率和 57 帧光照适应时间的表现, 本文提出的算法取得显著提升, 验证了其在运动目标检测中的有效性。

2 相关理论

2.1 高斯混合建模背景消除法

高斯混合建模背景消除法(Gaussian Mixture Model, GMM)通过从视频序列或图像中分离出动态目标, 达到去除背景突出运动目标的效果。其架构如图 1 所示, 该算法共有 3 个阶段: 背景模型建立阶段、背景前景分割阶段、背景模型更新阶段。




图 1 高斯混合建模背景消除法架构图

Fig. 1 Gaussian mixture model background subtraction architecture diagram

在高斯混合模型背景消除法中, 背景模型是通过每个像素点的亮度值采用 3~5 个高斯分布模型进行拟合来建立的。在背景与前景分割阶段, 每个

像素点都会与背景模型中其对应的高斯分布进行对比。如果该像素点的值能够被其中一个高斯分布有效“解释”, 则该像素点被认为属于背景, 否则记为前景。最后, 模型会不断更新每个像素点的背景模型, 以适应环境的变化。因此, 该方法适用于背景变化较小但包含一些周期性变化的场景(如树叶的轻微摆动或光线的变化)。

2.1.1 背景模型建立 (GMM)

在背景模型建立阶段每个像素点 (x, y) 可以用一个高斯混合模型来描述, 通常假设像素值的分布由 K 个高斯分布的线性组合构成, 表达式为

$$P(I_t(x, y)) = \sum_{k=1}^K \omega_k(x, y) \cdot \mathcal{N}(I_t(x, y); \mu_k(x, y), \sigma_k^2(x, y)) \quad (1)$$

式中: $\omega_k(x, y)$ 为第 k 个高斯分布的权重, 满足 $\sum_{k=1}^K \omega_k = 1$; $\mathcal{N}(\cdot; \mu, \sigma^2)$ 为高斯分布。每个高斯分布定义为

$$\mathcal{N}(I_t(x, y); \mu_k, \sigma_k^2) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(I_t(x, y) - \mu_k)^2}{2\sigma_k^2}\right) \quad (2)$$

式中: $\mu_k(x, y)$ 为第 k 个高斯分布的均值; $\sigma_k^2(x, y)$ 为第 k 个高斯分布的方差。

式(2)描述了像素点在第 k 个状态下像素值的概率密度。通过加权和, 背景模型能够表示多种背景状态。

2.1.2 背景前景分割

在背景与前景分割的过程中, 首先对当前帧中的每个像素值与背景模型中对应位置的多个高斯分布的均值进行差异计算。如果该像素值与背景模型的差异超过预设的阈值, 则该像素被认为属于前景, 即动态目标区域。这一过程有效地实现了背景与前景的分离, 从而实现对场景中运动目标的准确检测。前景判断公式为

$$F_t(x, y) = \begin{cases} 1 & |I_t(x, y) - \mu_k(x, y)| > k \cdot \sigma_k(x, y) \\ 0 & \text{其他} \end{cases} \quad (3)$$

式中: k 为用于控制灵敏度的系数, 一般取值 2~3。

通过该过程即可将场景的运动目标分割出来。

2.1.3 背景模型更新

背景模型的更新是为了适应场景的动态变化。在每次前景检测完成后, 背景模型中的每个高斯分布的参数都会根据当前帧的像素信息进行更新。

假设当前帧的像素值 $I_t(x, y)$ 匹配第 k 个高斯分布,

则更新该分布的均值、方差、权重分别为

$$\mu_k(x, y) \leftarrow (1 - \rho)\mu_k(x, y) + \rho \cdot I_t(x, y) \quad (4)$$

$$\sigma_k^2(x, y) \leftarrow (1 - \rho)\sigma_k^2(x, y) + \rho \cdot (I_t(x, y) - \mu_k(x, y))^2 \quad (5)$$

$$\omega_k(x, y) \leftarrow (1 - \rho)\omega_k(x, y) + \rho \quad (6)$$

式中： ρ 为学习速率，决定均值的更新速度。方差更新后，能够更好地描述当前状态下像素值的波动范围；权重更新后，可以反映当前帧中不同高斯分布的活跃程度。

2.2 注意力机制原理

近年来，注意力机制作为深度学习中的关键技术，广泛应用于自然语言处理和计算机视觉领域。在图像处理任务中，注意力机制能够模拟人类视觉聚焦的方式，对图像中的关键信息区域赋予更高的关注度，从而提升模型在复杂场景下的判别能力。

随着研究的不断深入，注意力机制在图像领域衍生出多种类型，分别针对空间维度、通道维度以及时间维度的信息建模，形成了多样化的结构体系。在这些机制中，空间注意力机制通过分析图像中像素与其邻域之间的空间相关性，突出显著区域，提高图像中目标的定位精度，广泛应用于图像分割、目标检测和运动识别等任务。通道注意力机制则关注特征图中不同通道的重要性，通过压缩与激励操作强化关键通道表达，常用于图像分类、特征融合和多尺度建模任务中。此外，时序注意力机制专注于建模图像序列或视频帧之间的时间依赖关系，能够捕捉帧间变化趋势，增强模型在视频目标检测、行为识别等时序任务中的适应能力。同时，自注意力机制通过建立图像中任意两点之间的全局依赖关系，有效提升了模型对上下文语义的理解水平，已被广泛应用于图像生成、超分辨率重建与复杂结构建模等领域。

虽然上述注意力机制各有优势，但在实际应用中应根据任务特点进行针对性的选择。本文研究的核心问题是运动目标检测，在该任务中，主要挑战体现在背景动态干扰较强、前景目标边界模糊，以及环境中光照、遮挡等突发因素频发等方面。为解决这些问题，本文结合检测过程中的两个关键阶段，选择引入空间注意力机制与时序注意力机制。其中，空间注意力机制被用于背景建模阶段，通过计算图像中每个像素与其邻域之间的相似性关系，引导模型更准确地构建背景模型，提升背景对复杂动态场景的适应能力；时序注意力机制则被应用于背景模

型更新阶段，借助历史帧与当前帧之间的相似性计算，自适应调整学习率，从而使模型能更快地应对光照突变等时序扰动，提高整体鲁棒性与响应速度。

在实现注意力机制的过程中，相似性函数与归一化方法的选择对模型性能影响显著。常用的相似性函数包括欧氏距离、点积、余弦相似度与马氏距离等。本文选择马氏距离作为相似度度量方法，主要考虑到该距离函数在计算时能够综合利用特征之间的协方差信息，这一点与本文所采用的高斯混合模型(GMM)背景建模方式在理论结构上高度契合。由于GMM本身依赖于像素的均值和方差建模背景，因此马氏距离更适合在该分布假设下衡量像素间的统计差异，有助于提升注意力机制中的相似性判断效果，进而增强模型的精度和稳定性。

在注意力权重的归一化阶段，常见方法包括Softmax函数、Sigmoid函数以及标准加权平均等。本文采用Softmax函数对注意力权重进行归一化，其优势在于能够将权重压缩至(0, 1)之间，并确保所有权重之和为1，从而具有良好的概率解释性。此外，Softmax函数具有放大显著差异的能力，能够强化关键区域或关键帧的响应效果，使得模型在空间维度上能更突出目标区域，在时序维度上能更快速地捕捉环境变化，特别适合本文所提出的联合建模结构。

3 TSA-BSGMM

本文提出一种基于高斯混合建模背景消除法的运动目标检测算法(Gaussian Mixture Model-based Background Subtraction method with Temporal and Spatial Attention mechanisms, TSA-BSGMM)，旨在提高运动目标检测的准确率的同时，可以适应例如光照突变等突发变化(见图2)。该算法分为3个部分：①基于空间注意力机制的背景模型建立；②基于形态学处理的背景前景分割；③基于时序注意力机制的背景模型更新；

在背景模型建立层引入空间注意力机制层，通过计算每个像素点与其邻域像素的加权关系，来调整背景模型参数。可以提高背景模型建立的准确性。

在背景前景分割层引入形态学处理，对于检测出的前景图像进行后处理，以去除噪声，填补空洞，维持或增强目标形状。使得前景目标更加连贯准确。




图2 TSA-BSGMM 架构图

Fig. 2 TSA-BSGMM architecture diagram

在背景模型层引入多级时序注意力机制, 通过计算当前帧与前几帧的相似度来调整当前帧背景模型更新时的学习率参数, 从而降低突发情况对背景模型更新的影响。

总体来说, 本文提出的 TSA-BSGMM 算法旨在传统的检测运动目标的基础上, 提高检测准确率, 并且可以使模型更好地适应突发变化(如突如其来的光照变化)。

3.1 基于空间注意力机制的背景模型建立

在传统 GMM 的背景模型建立过程中, 每个像素点的背景模型是根据该像素点历史值独立构建的。从而忽略了空间上像素点之间的关联性, 导致背景模型在动态场景下稳定性较差。

本文方法首先计算背景模型每个像素值和其邻域像素的相似性, 并将其归一化后得到空间注意力权重。最后将空间注意力加权更新背景模型的均值和方差, 从而得到最终的背景模型。

3.1.1 空间注意力权重计算

(1)定义邻域范围。为了计算某个像素点 (i, j) 的空间注意力, 需要先定义其邻域范围。假设选择一个 $(2R+1) \times (2R+1)$ 的窗口, 以像素点 (i, j) 为中心, 则窗口内的像素点坐标为 $(i+m, j+n)$, 其中 $m, n \in [-R, R]$ 。

(2)计算邻域像素的相似性。为了度量像素点 (i, j) 与其邻域点 $(i+m, j+n)$ 的相似性, 可以使用相似性函数, 常见的相似性度量包括欧式距离、点积、余弦相似度等。这里采用负欧式距离来表示相似性, 表达式为

$$\text{similarity}(x_{(i,j)}, x_{(i+m,j+n)}) = -\|x_{(i,j)} - x_{(i+m,j+n)}\|^2 \quad (7)$$

式中: $x_{(i,j)}$ 为像素点 (i, j) 的当前值; $\|\cdot\|^2$ 为欧式距离的平方。该相似性值越大(即距离越小), 表明两个像素点的特征越相似。

(3)计算空间注意力权重。基于像素点之间的

相似性值, 使用 Softmax 函数来归一化这些相似性值, 从而得到归一化后的空间注意力权重 $A_{(i,j),(i+m,j+n)}$, 即

$$A_{(i,j),(i+m,j+n)} = \frac{\exp(\text{similarity}(x_{(i,j)}, x_{(i+m,j+n)}))}{\sum_{k,l} \exp(\text{similarity}(x_{(i,j)}, x_{(i+k,j+l)}))} \quad (8)$$

分母部分是邻域中所有像素点的相似性值的指数和, 用于保证所有注意力权重的总和为 1。空间注意力权重 $A_{(i,j),(i+m,j+n)}$ 反映了邻域内每个像素点对中心像素 (i, j) 的相对贡献。

3.1.2 空间注意力权重加权更新背景模型参数

在计算出空间注意力权重 $A_{(i,j),(i+m,j+n)}$ 后, 可以基于这些权重对背景模型的参数(如均值和方差)进行加权更新。

(1)加权更新背景模型的均值。在背景建模阶段, 高斯混合模型会为每个像素点维持 K 个高斯分布(通常 $K=3$ 或 $K=5$)。在每一帧中, 对像素点 (i, j) 的均值 $\mu_{(i,j)}$ 进行加权更新, 表达式为

$$\mu_{(i,j)}^{\text{new}} = \sum_{m=-R}^R \sum_{n=-R}^R A_{(i,j),(i+m,j+n)} \cdot \mu_{(i+m,j+n)} \quad (9)$$

式中: $\mu_{(i+m,j+n)}$ 为邻域像素 $(i+m, j+n)$ 的均值; $A_{(i,j),(i+m,j+n)}$ 为像素点 $(i+m, j+n)$ 对中心像素 (i, j) 的注意力权重。

(2)加权更新背景模型的方差。同样地, 方差 $\sigma_{(i,j)}$ 也可以通过邻域加权来更新, 即

$$\sigma_{(i,j)}^{\text{new}} = \sum_{m=-R}^R \sum_{n=-R}^R A_{(i,j),(i+m,j+n)} \cdot \sigma_{(i+m,j+n)} \quad (10)$$

通过这种方式, 中心像素 (i, j) 的背景模型均值和方差不仅基于其自身历史值更新, 还会受到邻域像素值的影响, 从而增强了背景模型的空间一致性。

3.2 基于形态学处理的背景前景分割

传统 GMM 的前景检测部分。对于当前帧的每个像素点, 将其与当前背景模型的 K 个高斯分布进

行匹配,如果当前像素值符合某个高斯分布(即在该分布的均值附近),则认为该像素属于背景,否则判定该像素属于前景。但是在实际应用中,背景中的噪声会导致误判。

因此在本阶段引入形态学处理,对于检测出的前景图像进行后处理,以去除噪声,填补空洞,维持或增强目标形状,使得前景目标更加连贯准确。

在检测到前景后首先其进行开运算。开运算是先腐蚀再膨胀的组合操作,目的是去除小噪声点,保持前景的整体形状。因为腐蚀会缩小前景区域,接着膨胀可以恢复前景的主要结构,而不会再将小的噪声点带回来。随后再进行闭运算。闭运算是先膨胀再腐蚀的操作,可以填补前景中的小空洞和细小的黑色区域。

通过对分割出的前景进行开运算和闭运算后,得到去除噪声后的前景,由此得到更加准确的前景。

3.3 基于多级时序注意力机制的背景模型更新

在传统 GMM 的背景模型更新过程中,当判定当前像素点为背景时,会将当前像素值更新至背景,这种更新方法只考虑上一帧的影响,会导致模型无法应对突发变化(例如突如其来的光照会导致背景模型更新噪音较大)。

因此本文通过引入多级时序注意力机制来解决这个问题,为不同时刻的背景模型更新的学习率赋予不同的权重,进行动态调节学习率,从而降低突发情况对背景模型更新的影响。

在背景模型更新部分分为 2 个阶段:首先,计算当前帧与历史帧的相似度,通常计算马氏距离;随后,为每个时间段引入了不同的加权策略,对于前几帧(如 2~5 帧),采用较强的注意力加权,以确保背景模型能够快速响应当前帧的变化。而对于更久远的历史帧,则采用较小的加权值,减小其对当前背景模型更新的影响。这种加权机制能够有效地避免突发光照变化等短期事件对背景模型更新的影响,同时保持对长时间变化的适应性。最终通过多级时序注意力机制对背景模型更新时的学习率进行加权调控,从而动态调节背景模型更新速度,进而应对突然光照等突发变化。结构如图 3 所示。

3.3.1 计算多级时序注意力权重

多级时序注意力机制的核心是为不同时刻的观测值赋予不同的权重,以便模型能够更关注关键帧。通过一个相似性函数计算每一时刻的注意力权重 α_t ,以判断当前观测值对背景模型的贡献程度。

<https://mc.spacejournal.cn>




图 3 基于多级时序注意力机制的背景模型结构

Fig. 3 Background model structure based on temporal attention mechanism

假设当前时间为 t ,对像素 (i, j) 的历史观测值 $\{x_1, x_2, \dots, x_{t-1}\}$ 计算与当前观测值 x_t 的相似性,用以衡量其对当前帧背景模型的影响。多级时序注意力权重计算公式为

$$\alpha_t = \frac{\exp(\lambda_t \cdot f(x_t, h_{t-1}))}{\sum_{k=1}^t \exp(\lambda_k \cdot f(x_k, h_{t-1}))} \quad (11)$$

式中: $f(x_t, h_{t-1})$ 为一个相似性函数,衡量当前帧的观测值 x_t 与历史观测的相关性,本文以马氏距离来定义。

对于两个向量 x_t 和 h_{t-1} ,马氏距离的计算公式为

$$D_M(x_t, h_{t-1}) = \sqrt{(x_t - h_{t-1})^T S^{-1} (x_t - h_{t-1})} \quad (12)$$

式中: S 为样本的协方差矩阵; $(x_t - h_{t-1})$ 为两个样本之间的差异; λ_t 为与历史帧的时间跨度相关的权重因子,通常定义为

$$\lambda_t = \begin{cases} \lambda_1 & t \leq 5 \\ \lambda_2 & 6 \leq t \leq 10 \\ \lambda_3 & t > 10 \end{cases} \quad (13)$$

式中: $\lambda_1 > \lambda_2 > \lambda_3$,即较近的历史帧具有更高的权重。

3.3.2 多级时序注意力权重更新背景模型参数

在匹配新观测值后,利用多级时序注意力对背景模型的高斯分布参数(均值、方差和权重)进行加权更新。这样可以在快速变化的场景中有效增强背景模型的适应能力。

设学习率为 α ,在匹配新观测值时,根据多级时序注意力权重调整高斯分布的均值。若新观测值 x_t 匹配第 i 个高斯分布,则均值的更新公式为

$$\mu_i^{\text{new}} = (1 - \alpha \cdot \alpha_t) \mu_i + (\alpha \cdot \alpha_t) x_t \quad (14)$$

式中: α_t 为多级时序注意力权重,控制当前帧对均值更新的贡献; α 为学习率,控制更新的速率。此更新公式中,当注意力权重 α_t 较大时,当前帧的观测值 x_t 对均值的影响较大,这种加权使得背景模型

能够在关键时刻快速调整。

类似地, 利用多级时序注意力权重对方差进行更新, 使得方差在关键帧上的更新幅度更大。表达式为

$$\sigma_i^{\text{new}} = (1 - \alpha \cdot \alpha_t) \sigma_i + (\alpha \cdot \alpha_t) (x_t - \mu_i)^2 \quad (15)$$

式中: σ_i 为方差; $(x_t - \mu_i)^2$ 为当前观测值与均值的偏离程度。当注意力权重 α_t 较大时, 方差更新幅度也较大, 能够更快地适应当前场景的动态变化。

权重更新表达式为

$$\omega_k(x, y) \leftarrow (1 - \alpha) \omega_k(x, y) + \alpha \quad (16)$$

权重更新后, 可以反映当前帧中不同高斯分布的活跃程度。

4 实验

4.1 数据集构建

为验证本文算法在运动目标检测中的有效性, 采用数字孪生技术来构建测试数据集, 该数据集由

4 部分组成: 原始视频、每一帧运动目标的二值图像、每一帧中运动目标的像素点位置以及光照突变的时间。该数据集包含 50 条视频, 每条视频时长为 60 s。

本文首先在 Unity 场景中构建真实户外场景, 接着在场景中创建白色立方体模拟运动目标随机运动, 通过将方块的大小参数与后台程序相结合, 准确获取运动目标的所有像素点位置, 最后在场景中加入突变的光照, 以此获得测试使用的数据集。

首先在 Unity3D 中构建真实测试场景, 如图 4 所示。场景内的花草树木会有轻微摆动, 以还原场景的真实性。

随后在场景中导入立方体对象, 并通过后台程序控制其随机飞行, 场景图片如图 5 所示。

最后, 在 Unity 场景中模拟光照突变, 在每个测试视频的 10 ~ 20 s 以及 30 ~ 40 s 的时间段内加入光照变化。加入光照后的场景图像如图 6 所示。



图 4 Unity 场景



Fig. 4 Unity scene



图 5 导入白色方块后的场景

Fig. 5 The scene after importing a white cube



图 6 加入光照突变的场景

Fig. 6 The scene with sudden lighting changes

4.2 评价指标

本文共有两个评价指标, 分别是用于评价运动目标检测的准确程度的准确率(Accuracy, 记为 A)和模型适应光照变化能力的 L-FPS(适应光照的帧数)。

准确率为衡量模型整体的分类正确率, 即正确

预测(正类和负类)占有所有样本的比例。计算公式为

$$A = \frac{TP + TN}{TP + TN + FP + FN} \quad (17)$$

式中: TP (True Positive) 为模型正确预测为正类的样本数量; TN (True Negative) 为模型正确预测为负类的样本数量; FP (False Positive) 为模型错误地将

负类预测为正类的数量，即“假阳性”； FN (False Negative)为模型错误地将正类预测为负类的数量，即“假阴性”。

L-FPS(适应光照的帧数)，指的是在光照变化出现后，模型检测准确率恢复到光照变化前准确率的 90% 所需的帧数。

4.3 实验设置

本次实验在真实楼宇中搭建测试，所用配置：服务器为联想 SR650，运行系统为 Ubuntu22.04，CPU 为 4210R，内存为 256 GB，GPU 为 NVIDIA GeForce RTX4090，显存为 24 GB。

高斯分布数量设为 5 个，以适应场景中可能出现的多状态背景模型；前景判定阈值 K 设置为 2.5，若当前帧像素值与背景模型中高斯分布均值的差距小于该阈值对应的标准差倍数时，认为其属于背景。该设置在保证检测灵敏度的同时抑制了背景噪声的干扰。

4.4 结果与分析

4.4.1 对比实验

为证明本文提出的 TSA-BSGMM 算法的有效性，将其与当前主流的几种运动目标检测算法在本文构建的测试数据集上进行对比，实验结果如表 1 所示。结果表明，TSA-BSGMM 算法在运动目标检测准确率和适应光照突变的速度上均表现出显著的优势。具体而言，TSA-BSGMM 的准确率为 87.92%，明显高于背景消除法(85.83%)和 SuBSENSE(86.94%)等其他算法。此外，TSA-BSGMM 算法在适应光照突变所需的帧数上仅为 13 帧，远低于背景消除法(57 帧)、帧间差分法(108 帧)等算法，体现了其在适应光照突变上的优越性。

图 7 ~ 图 12 分别展示了对比实验中各方法在第 270 帧时的检测结果，从图中可以看出本文方法检测到的运动目标相对完整，且背景噪声较小。

表 1 对比实验结果

Tab. 1 Comparative experimental results

Algorithm	Accuracy/%	L-FPS	帧率/(frame·s ⁻¹)
TSA-BSGMM	87.92	13	38.2
背景消除法	85.83	57	45.7
帧间差分法	79.03	108	61.5
T2FMRF_UV	77.41	75	53.1
PBAS	76.95	64	33.5
SuBSENSE	86.94	48	28.4




图 7 TSA-BSGMM 第 270 帧

Fig. 7 Frame 270 of TSA-BSGMM



图 8 背景消除法第 270 帧

Fig. 8 Frame 270 of the Background Subtraction Method




图 9 帧间差分法第 270 帧

Fig. 9 Frame 270 of the Frame Difference Method




图 10 T2FMRF_UV 第 270 帧

Fig. 10 Frame 270 of T2FMRF_UV




图 11 PBAS 第 270 帧

Fig. 11 Frame 270 of PBAS




图 12 SuBSENSE 第 270 帧
Fig. 12 Frame 270 of SuBSENSE

图 13 和图 14 展示了该算法与其他算法在运动目标检测任务中的可视化对比。可以看出: TSA-BSGMM 在复杂背景和光照变化下仍能稳定地检测到运动目标, 而其他算法则出现了较多的误检和漏检现象。此外, TSA-BSGMM 能够快速适应光照突变, 维持较高的检测精度, 而其他算法则需要较长的时间才能恢复。这些结果表明, TSA-BSGMM 算法在实际应用中具有更强的鲁棒性, 能够更好地应对复杂环境中的挑战。




图 13 TSA-BSGMM 第 320 帧检测结果
Fig. 13 TSA-BSGMM detection result at frame 320



图 14 背景消除法第 320 帧检测结果
Fig. 14 Background subtraction method frame 320 detection result

4.4.2 消融实验

为了验证本文提出的基于空间注意力机制的背景模型建立、基于形态学处理的背景前景分割以及基于多级时序注意力机制的背景模型更新的有效性, 本文进行消融实验来评估不同模块对运动目标检测算法性能的影响。实验结果如表 2 所示。

结果表明, 在背景模型建立阶段引入空间注意力机制后对运动目标检测结果有积极影响, 对比基

线高斯混合建模背景消除法, 准确率提高了 0.38%。证明本文提出的基于空间注意力机制的背景建模的有效性, 提高了运动目标检测的准确率。但对适应光照的能力几乎没有改变。

表 2 消融实验结果
Tab. 2 Ablation experiment results

组号	空间注意力 机制	形态学 处理	多级时序 注意力机制	Accuracy/%	L-FPS
1				85.83	57
2				86.21	59
3				87.33	51
4				87.92	13

在背景前景分割阶段引入形态学处理后, 对模型的能力同样有进一步的提升, 准确率从 86.21% 提升至 87.92%, 共提升了 1.71%。但当前模块的改进对于光照适应能力依旧没有改变。

最后, 本文在背景模型更新阶段引入多级时序注意力机制后, 对于模型的准确率提高并不明显, 但有效的提高了模型对于光照突变的适应能力, 从基线模型需要 57 帧才可以适应光照, 缩短到了 13 帧便可适应光照。

4.4.3 多目标密度下的算法性能评估实验

为了进一步验证 TSA-BSGMM 算法在复杂环境下的适用性边界, 本文设计了一项实验, 旨在考察视场内运动目标数量递增对算法性能的影响。具体实验设置如下: 在 Unity 测试场景中, 分别导入 1~20 个白色目标块, 并为每种目标数量设置不同的实验视频, 最终生成共计 20 条视频, 每条持续 60 s。每个目标沿着随机轨迹和速度运动, 同时背景中加入树叶微动等动态元素, 以增加实验环境的复杂性。

对比算法为传统的高斯混合模型(GMM)背景消除方法, 通过比较两种算法在不同目标数量和复杂背景条件下的表现, 评估 TSA-BSGMM 算法在复杂环境中的适用性与优势。

检测准确率随目标数量变化的实验结果如表 3 所示。从实验结果可以观察到, 随着运动目标数量增加, 两种方法的检测准确率均逐渐下降。传统 GMM 方法在目标数量超过 10 个后下降幅度较大, 至 20 个目标时准确率降低至 68.7%; TSA-BSGMM 方法得益于引入空间注意力机制和形态学处理, 相比传统 GMM 下降速度略缓, 20 个目标时仍保持 79.2% 的准确率。

从实验结果可以观察到,随着运动目标数量增加,两种方法的检测准确率均逐渐下降。传统 GMM 方法在目标数量超过 10 个后下降幅度较大,至 20 个目标时准确率降低至 68.7%; TSA-BSGMM 方法得益于引入空间注意力机制和形态学处理,相比传统 GMM 下降速度略缓,20 个目标时仍保持 79.2% 的准确率。

表 3 多目标密度下的算法性能评估实验结果

Tab. 3 Performance evaluation of the algorithm under different target density conditions

目标数量	TSA-BSGMM 准确率 /%	GMM 准确率 /%
1	87.9	85.8
5	86.7	84.5
10	85.5	80.6
15	83.8	76.2
20	79.2	68.7

总体来看, TSA-BSGMM 在多目标复杂场景下表现出更好的鲁棒性,但当运动目标数量进一步增加,检测准确率亦会随之下降,说明该方法在高密度运动目标场景下存在一定的适用性边界。

4.4.4 参数选择分析实验

为了验证 TSA-BSGMM 算法中空间注意力机制与多级时序注意力机制关键参数设置的合理性,本文针对空间邻域窗口大小及背景模型更新学习率进行了系统性的参数敏感性实验。

在空间注意力机制中,邻域窗口大小($N \times N$)直接影响背景模型对局部空间一致性的建模能力。窗口过小容易忽略局部特征关联性,窗口过大则会引入不相关背景干扰。因此,本文设置了 $N=3、5、7、9、11$ 这 5 种不同大小进行实验,结果如表 4 所示。

表 4 窗口大小对模型性能的影响

Tab. 4 Effect of window size on model performance

窗口大小 ($N \times N$)	Accuracy /%	FPS
3×3	86.92	50.26
5×5	87.92	38.20
7×7	86.41	26.14
9×9	85.96	22.12
11×11	85.24	20.11

从表 4 中可以看出,当窗口大小为 5×5 时,检测准确率和光照适应速度均达到最佳,超过或小于此尺寸均导致性能下降。因此,本文最终选择 5×5

作为空间注意力机制的邻域窗口大小。

在背景模型更新过程中,学习率(α)决定了模型对于环境变化的响应速度。为兼顾准确率与适应性,因此本文设置 α 为 0.001、0.005、0.010、0.015 和 0.020 这 5 种不同值进行对比实验,实验结果如表 5 所示。

表 5 学习率对模型性能的影响

Tab. 5 Impact of learning rate on model behavior

学习率 α	Accuracy /%	L-FPS
0.001	86.87	25
0.005	87.12	19
0.010	87.92	13
0.015	87.06	11
0.020	86.84	10

可以观察到,学习率 $\alpha=0.01$ 时,在保证检测准确率的同时,能够以最优速度适应突发光照变化。因此,本文选择 $\alpha=0.010$ 作为最终设置。

5 结束语

本文提出了一种基于多级时序和空间注意力机制的高斯混合建模背景消除法(TSA-BSGMM),提高在复杂背景和光照突变等环境运动目标检测的鲁棒性。该算法通过在背景建模阶段引入空间注意力机制,并在背景前景分割阶段结合形态学处理,显著的提高了在树叶晃动等复杂背景下运动目标检测的准确率。此外,通过在背景模型更新阶段引入多级时序注意力机制,增强了模型在面对光照突变等突发环境变化时的适应性。

实验结果表明, TSA-BSGMM 在准确率和光照适应速度方面均优于传统背景消除法、帧间差分法以及其他现有运动目标检测算法。具体而言, TSA-BSGMM 的检测准确率达到 87.92%,并且能够在 13 帧内适应光照突变,对比其他运动目标检测算法在同等条件下表现出更高的鲁棒性。消融实验进一步验证了各个模块(空间注意力机制、形态学处理和多级时序注意力机制)在提高运动目标检测性能中的有效性。

因此, TSA-BSGMM 为解决运动目标检测在复杂背景与突发环境变化时准确率下降的问题提供了一种有效方法,具有广泛的应用前景,尤其适用于安防监控、智能交通、自动驾驶等领域。未来的研究可以进一步优化该算法,以应对更复杂的环境变

化, 提升其在多变条件下的适应能力和检测精度。

参考文献:

- [1] LIU S, WANG J. Research on motion target detection method based on deep frame difference convolutional neural network[J]. *Acta Electronica Sinica*, 2020, 48(12): 2763-2774.
- [2] ZHANG W, ZHAO X. Driver fatigue detection method based on stack autoencoder for EEG signals[J]. *Journal of Testing Technology*, 2023, 40(2): 258-265.
- [3] WU L, CHEN H. Lightweight object detection algorithm based on improved SSD[J]. *Journal of Testing Technology*, 2023, 40(2): 278-286.
- [4] LI T, JIANG L. Multi-vessel tracking and traffic flow statistics based on deep learning[J]. *Microcomputer Applications*, 2020, 37(3): 185-191.
- [5] ANSARI M A, SINGH D K. Human detection techniques for real time surveillance: A comprehensive survey[J]. *Multimedia Tools and Applications*, 2021, 80(6): 8759-8808. DOI: [10.1007/s11042-020-10103-4](https://doi.org/10.1007/s11042-020-10103-4).
- [6] AZEEZ B, ALIZADEH F. Review and classification of trending background subtraction-based object detection techniques[C]// 2020 6th International Engineering Conference “Sustainable Technology and Development” (IEC). Piscataway: IEEE, 2020: 185-190. DOI: [10.1109/IEC49899.2020.9122929](https://doi.org/10.1109/IEC49899.2020.9122929).
- [7] SABEENA S J, VIJILA S A. Moulded RSA and DES (MRDES) algorithm for data security[J]. *International Journal on Recent and Innovation Trends in Computing and Communication*, 2023, 11(2): 154-162. DOI: [10.17762/ijritcc.v11i2.6140](https://doi.org/10.17762/ijritcc.v11i2.6140).
- [8] ĐOKIĆ L, JOKIĆ A, PETROVIĆ M, et al. Application of metaheuristic optimization algorithms for image registration in mobile robot visual control[J]. *Serbian Journal of Electrical Engineering*, 2021, 18(2): 155-170. DOI: [10.2298/SJEE2102155D](https://doi.org/10.2298/SJEE2102155D).
- [9] HE Z, LI Q, FENG H J, et al. Class agnostic moving target detection by color and location prediction of moving area[J]. *Optik*, 2022, 251: 168002. DOI: [10.1016/j.ijleo.2021.168002](https://doi.org/10.1016/j.ijleo.2021.168002).
- [10] WANG M, LI T, ZHANG L. FPGA-based detection system for slow-moving, small aerial targets[J]. *Optics Journal*, 2020, 40(6): 064201.
- [11] ZHOU Z, YU X, ZHANG X. Real-time vehicle detection for aerial video processing[J]. *Journal of Remote Sensing*, 2020, 24(9): 1410011.
- [12] ZHANG Q, LI N, WANG G. Motion target detection algorithm based on improved ViBe and multi-feature fusion[J]. *Computer Science and Applications*, 2022, 12(2): 45378353.
- [13] KHATRI K, SHARMA A. ECG signal analysis for heart disease detection based on sensor data analysis with signal processing by deep learning architectures[J]. *Research Journal of Computer Systems and Engineering*, 2020, 1(1): 6-10. DOI: [10.52710/rjcs.11](https://doi.org/10.52710/rjcs.11).
- [14] TAH A, ROY S, DAS P, et al. Moving object detection and segmentation using background subtraction by kalman filter[J]. *Indian Journal of Science and Technology*, 2017, 10(19): 1-11. DOI: [10.17485/ijst/2017/v10i19/95427](https://doi.org/10.17485/ijst/2017/v10i19/95427).
- [15] ALI Y H, MOHAMMED M R. Extracting background model in video surveillance by using hybrid techniques[J]. *Al-Mansour Journal*, 2019(31): 48-64.
- [16] FERNÁNDEZ-RODRÍGUEZ M, SILVA B, QUEIRÓS S, et al. Exploring optical flow inclusion into nnU-Net framework for surgical instrument segmentation[C]// *Medical Imaging 2024: Image-Guided Procedures, Robotic Interventions, and Modeling*. 2024.
- [17] 汤旻安, 王晨雨. 基于改进 ViBe 算法的静态场景运动目标检测[J]. *激光与光电子学进展*, 2021, 58(14): 1410011. DOI: [10.3788/LOP202158.1410011](https://doi.org/10.3788/LOP202158.1410011).
TANG M A, WANG C Y. Moving object detection in static scene based on improved ViBe algorithm[J]. *Laser & Optoelectronics Progress*, 2021, 58(14): 1410011. DOI: [10.3788/LOP202158.1410011](https://doi.org/10.3788/LOP202158.1410011).
- [18] JEEVITH S H, LAKSHMIKANTH S, SANDEEP K K. A hybrid approach for background subtraction in video: Combining RPCA, LBP, and grassmann average[J]. *International Journal of Intelligent Systems and Applications in Engineering*, 2023, 11(7S): 299-310.
- [19] MOHANTY S K, RUP S. An adaptive background modeling for foreground detection using spatio-temporal features[J]. *Multimedia Tools and Applications*, 2021, 80(1): 1311-1341. DOI: [10.1007/s11042-020-09552-8](https://doi.org/10.1007/s11042-020-09552-8).

作者简介:

闫禹树 硕士研究生, 568333635@qq.com

许川佩(通信作者) 博士, 教授, xcp@guet.edu.cn