

深度帧差 CNN 下激光雷达交通视频图像运动目标检测

江雪芸, 焦 勇, 郭丽君

兰州博文科技学院, 兰州 730101

摘 要: 激光雷达交通视频图像检测中, 传统帧差法在面对目标运动速度过快或过慢时, 往往难以有效区分并准确捕捉运动目标。针对这一问题, 提出深度帧差结合卷积神经网络(CNN)的激光雷达交通视频图像运动目标检测方法。首先通过帧差法捕捉连续帧之间的像素变化, 采用 CNN 模型深度挖掘并提取这些变化中的关键目标特征矢量, 通过 CNN 的平均池化层进一步精炼和压缩了特征表示, 有效去除了冗余信息, 同时保留了对于区分运动目标至关重要的特征。实验结果显示, 相较于其他对比方法, 该方法能够更精确地识别并跟踪不同速度下的运动目标, 为智能交通系统的构建提供了强有力的技术支持。

关键词: 激光雷达; 运动目标检测; 深度卷积神经网络; 帧差法; 视频图像

中图分类号: TN39 **文献标识码:** A **doi:** 10. 14016/j. cnki. jgzz. 2025. 08. 134

Moving object detection in LiDAR traffic video images under deep frame difference CNN

JIANG Xueyun, JIAO Yong, GUO Lijun

Lanzhou Bowen College of Science and Technology, Lanzhou 730101, China

Abstract: In the detection of traffic video images using LiDAR, the traditional frame difference method often struggles to effectively distinguish and accurately capture moving targets when facing targets with excessively fast or slow motion speeds. To address this issue, a laser radar traffic video image motion object detection method combining deep frame difference and convolutional neural network (CNN) is proposed. Firstly, the pixel changes between consecutive frames are captured using the frame difference method, and the CNN model is used to deeply mine and extract the key target feature vectors in these changes. The feature representation is further refined and compressed through the CNN's average pooling layer, effectively removing redundant information while preserving the features that are crucial for distinguishing moving targets. The experimental results show that compared with other comparative methods, this method can more accurately identify and track moving targets at different speeds, providing strong technical support for the construction of intelligent transportation systems.

Key words: LiDAR; motion target detection; deep convolutional neural network; frame difference method; video images

1 引言

激光雷达通过发射激光束并接收反射信号来获取目标的三维位置信息, 具有不受光照条件影响、测

距精度高、抗干扰能力强等优点^[1]。应用其采集交通视频图像后, 需要对车辆、行人等运动目标进行检测^[2], 以便于交通违规行为的分析^[3]。因此, 开发能够适应不同交通环境^[4]、具备高适应性和高准确度的运动目标检测方法成为重点研究目标。

为了应对这些挑战, 研究者们提出了多种运动目标检测方法。其中, 文献[5]提出了一种基于体素柱的3D点云对象检测方法, 通过稀疏卷积和特征编码

收稿日期: 2025-02-13

基金项目: 甘肃省教育厅科技创新项目(No. 2021A-201)、甘肃省档案科技项目(No. GS-2023-X-02)

作者简介: 江雪芸(1974-), 女, 副教授, 研究方向: 计算机, 人工智能, 物联网, 嵌入式。

<http://www.laserjournal.cn>

提高点云的空间语义信息。该方法的弊端是当目标运动速度过快时,可能会导致体素柱内的点云数据在连续帧之间变化剧烈,使得特征编码难以稳定地捕捉目标的动态特征,从而影响检测精度。文献[6]则基于 Swin Transformer 改进了点柱算法,引入自注意机制提升特征抽取性能。当目标运动速度过快时,自注意机制难以在有限的时间窗口内捕捉到目标的完整动态特征,导致检测性能下降。文献[7]利用激光雷达实时建立前方边界,通过时空交换和多帧信息提升轨迹提取稳定性。当目标运动速度过快时,激光雷达的扫描频率可能不足以捕捉到目标的完整轨迹,导致轨迹提取出现断裂或错误。而目标运动速度过慢时,虽然轨迹提取的稳定性较高,但可能导致系统对静态障碍物的误判,特别是在动态环境中。文献[8]结合了视觉和 2D 激光雷达进行目标探测,通过聚类算法和卡尔曼滤波器实现目标跟踪。当目标运动速度过快时,由于视觉传感器的曝光时间不足以捕捉到清晰的图像,这会导致聚类算法难以准确地分割目标。另一方面,当目标运动速度过慢时,虽然视觉传感器受到的影响较小,但卡尔曼滤波器的预测模型可能会因为长时间处于低动态状态而进行不必要的计算,或者预测误差会逐渐累积,增加了目标跟踪的难度。

2 基于深度帧差 CNN 的运动目标检测

2.1 图像帧差法的图像前景背景分离

在激光雷达交通视频图像的运动目标检测中,由于运动目标在视频序列中会产生像素值的变化,而背景则相对稳定,因此通过比较相邻帧的像素差异,可以有效地识别出运动目标。帧差法算法相对简单,计算量小,易于实现,能够满足交通视频监控等场景对实时性的要求^[9-11]。该方法主要依赖于相邻帧之间的像素变化,因此对光照的突然变化相对不敏感。这在交通监控等户外场景中尤为重要,因为光照条件往往会发生较大变化。此外,帧差法能够有效地削弱背景信息,使检测结果更加聚焦于运动目标本身。这一特性有助于降低背景噪声对检测结果的干扰,从而提高运动目标检测的准确性和可靠性。

假设 $S_k(x, y)$ 是增强后图像的第 k 帧, $S_{k-\tau}(x, y)$ 是图像的第 $k-\tau$ 帧, τ 是图像帧数的差分间隔^[12],那么这两个图像帧之间的差 $D_k(x, y)$ 可以表示为

$$D_k(x, y) = |S_k(x, y) - S_{k-\tau}(x, y)| \quad (1)$$

然后对 $D_k(x, y)$ 进行二值化计算^[13],可以得到:

$$R_k(x, y) = \begin{cases} 1, & D_k(x, y) > T \\ 0, & otherwise \end{cases} \quad (2)$$

公式中, T 是二值化计算时所选择的阈值,通常根据具体情况而定。帧差法流程如图 1 所示。




图 1 帧差法流程

基于帧差法的前景背景分类步骤为:

(1) 通过公式(1)计算得到第 k 和 $k-\tau$ 帧图像的差值绝对值,求出两帧图像的差分值。

(2) 将差值图像 $D_k(x, y)$ 进行二值化,若差分后的图像亮度高于阈值 T ,则判断为图像前景点,反之则为图像背景点。

(3) 采用形态滤波过滤^[14]。二值图像中常有噪声,采用形态学方法滤除噪声。

(4) 连接分析。如果图像前景内部有孔洞,需要对其进行连接,可先求出孔洞周边连通区域^[15],若该区域比给定的范围大,则判断该区域为运动前景,反之为背景。

综上所述,采用帧差法通过比较连续帧之间像素的细微变化,有效地区分了前景运动目标与静态背景。此方法不仅能够准确地捕捉并检测出视频中的运动目标,还展现出较高的实时处理能力和对光照变化的一定适应性,从而确保了在不同光照条件下检测的连续性和稳定性。然而,需要注意的是,帧差法也存在一些局限性。当目标物体的速度太快时,前、后两帧的视频图像不能完全重合,无法区分前景中车辆、行人运动目标与枝条、草木等非检测目标;当目标物体的速度太慢时,则会造成前景的交叠,漏检运动目标。因此,在实际应用中需要结合其他方法以提高检测的准确性和鲁棒性。

2.2 深度卷积神经网络的目标检测

在激光雷达交通视频图像运动目标检测过程中,帧差法通过比较相邻帧之间的差异来检测运动目标,

这种方法简单且计算效率高,但对于速度过快或过慢的运动目标时,其检测效果受限,细微的帧间变化可能不足以明确界定运动状态。为了克服这一局限,本研究引入卷积神经网络对帧差结果进行深度处理。DCNN 自动提取并学习帧间变化的复杂目标特征矢量,这些特征极大地增强了模型对图像细微变动的敏感度,使其能够识别出更多细节。训练后的 DCNN 模型,在面对速度多变的运动目标时,依然能够准确区分前景图像中的不同运动个体,如车辆、行人等,实现精准检测^[16]。

对于一组输入的前景数据集 $A = \{I_1, I_2, \dots, I_N\}$, 利用卷积神经网络进行层次化的特征抽取和过滤^[17], 得到的运动目标特征 B_A 可以表示为

$$B_A = \psi[c_\varphi(I_1), c_\varphi(I_2), \dots, c_\varphi(I_N)] \quad (3)$$

公式中, $c_\varphi(\cdot)$ 是图像基于卷积神经网络训练提取的目标特征; φ 是网络模型参数; $\psi(\cdot)$ 是模型的复合函数, 可以把不同尺寸的图像集合最后转化成一个固定尺寸的特征矢量。

残差网络是一种常用的深层卷积神经网络^[18], 它通过对残差的堆栈结构进行建模, 利用跳变连接和恒等映射来克服网络性能下降的问题, 使整个网络同时具有较强的梯度扩散和迁移泛化能力, 以适应基础网络对目标特征 B_A 的抽取需要。

所提方法使用的运动目标检测中的残差网络和残差模块的构成部分如图 2 所示。




图 2 残差网络结构

为处理前景图像运动目标的重叠问题, 首先, 将基于帧差法获得的前景图像和原图像作为辅助子信道, 并将其输入到深度卷积神经网络中进行训练。由

于网络信道数量的增多, 实际输入维数与原残差网络的输入维数存在差异, 所以采用三通道加权卷积层替代神经网络输入层, 首层卷积网络层实现对图像基本特征的提取, 为下一步运动目标的特征提取打下良好的基础。

假设一个与前一层的输出特性相吻合的卷积网络层 l , 使用激励函数生成此层的输出 a^l , 并对输出结果和特征量进行卷积训练:

$$a^l = G\left[\sum_{i=1}^{M_{l-1}} (a^{l-1} * w^i) + b^l\right] \quad (4)$$

公式中, $G(\cdot)$ 是激活函数; M 是训练样本总数量; w^i 是相应的权重指数; a^{l-1} 是第 $l-1$ 层的特征输出值; b^l 是模型的偏置指数。

深度卷积神经网络在训练阶段不是直接使用单一全连接层检测目标的, 而是通过全连接模块对图像目标进行分类。全连接模块由两个全连接层组成, 在层间分别嵌入了规则层、激活函数和损失层。双重全连接层的神经元以类似于自编码机的模式进行连接, 通过两个完全连通的层次, 实现了目标特征和目标分类之间的有效联系, 提高了两者的契合度。

隐藏层的输入是通过对输入信号进行线性和非线性转换得到的, 设图像特性矢量 e^l , 相应的隐藏层为

$$e^l = \text{ReLU}(w^l e^{l-1} + b^l) \quad (5)$$

公式中, $\text{ReLU}(\cdot)$ 是激活层计算函数。

规则层能将隐藏层的输出规范化, 减少对原图的依赖, 加快网络收敛速度。同时, 由于损失层的存在, 使得网络的参数在某种程度上变得稀疏, 从而避免了训练的过度学习。

假定神经网络的第 l 层是批量标准化层, z^l 是输入层数据, 维数 (n, i^l) , 这里 n 是抽样数目, i^l 是第 l 层神经元的数目, z^l 标准化为

$$z^{\text{nor}, l} = \frac{z^l - \alpha * (z^l)^M}{\alpha + \xi} \quad (6)$$

公式中, α 是列矢量; ξ 是标准化的调节指数。

引入学习指数 γ 和 β 可以得到规则层的输出, 即前景图像中运动目标检测结果:

$$BN_{\gamma, \beta}(z^l) = \alpha * \gamma * z^{\text{nor}, l} + \alpha * \beta \quad (7)$$

经过深度卷积神经网络学习训练可提高前景图像中不同运动个体之间的差异性。当差分两帧中, 运动目标速度过快或过慢时都能实现对车辆、行人等交通运动目标地精准检测。

3 目标检测实验

为了验证所提方法在激光雷达交通视频图像运动目标检测中的性能优势,设计了一系列对比实验,将该方法与基于体素柱形的检测方法、基于改进 PointPillars 的检测方法以及基于视觉与 2D 激光雷达的检测方法作对比,证明所提方法在实践中的优势。实验所用参数如表 1 所示。

表 1 实验参数

实验参数	数值
样本数量	1 000
学习率	0.002
批次大小	128
迭代次数	20 000
权重衰减	0.000 4
动量	0.8
学习率变化指数	0.2

本实验采用了一些公开的交通场景数据集,其中包括 KITTI、nuScenes 数据集,这些数据集包含大量的激光雷达点云数据和对应的视频图像,涵盖了多样化的交通场景及多变的天气条件。为了进一步贴近实际应用场景,实验前还额外采集了一部分激光雷达交通视频数据,这些数据通过安装在车辆上的激光雷达与摄像头实现同步采集,采集的场景广泛覆盖了城市道路、高速公路、交叉口等多种交通环境,最终构建了一个庞大的激光雷达交通场景数据集,总计包含 1 507 214 帧数据,为实验提供了坚实的数据基础。部分图像如图 3 所示。



(a) 图像 1



(b) 图像 2



(c) 图像 3



(d) 图像 4

图 3 部分图像示意图

为了全面评估检测方法的性能,数据集还包含了标注信息。这些标注数据由专业的标注人员完成,准确标明了场景中车辆、行人等关键运动目标的类别、精确位置以及边界框等关键信息。这些标注数据不仅为检测方法提供了明确的参考标准,也是衡量检测方法准确性、可靠性以及鲁棒性的重要依据。

3.1 方法性能

为了验证所提方法对激光雷达交通视频图像中运动目标检测的有效性,采用 AUC 面积作为核心评价指标。AUC 区域面积愈趋近于 1,表示该检测方法的性能越优越。为了确保性能评估的公正性和客观性,从样本集中随机抽取一幅图像,并在相同的实验条件下,应用 4 种不同的方法对图像中的目标进行检测。实验过程中计算并比较了这 4 种方法的 AUC 面积,结果如图 4 所示。




图 4 AUC 面积


从图 4 中可以看出,所提出方法的 AUC 面积更接近 1,这充分证明了所提方法在运动目标检测方面具有较高的真实性和准确性。相比之下,基于体素柱形的检测方法的 AUC 面积最小,说明该方法在检测真实场景中的运动目标时,其性能相对较低。这一对比结果进一步验证了所提方法的有效性和优越性。

3.2 检测效果


为了全面评估不同检测方法在应对不同速度下运动目标检测任务中的性能,从样本测试集中挑选了 4 张具有代表性的视频图像。这些图像涵盖了车辆、行人等运动目标在不同速度状态下的场景,旨在模拟真实交通环境中的复杂情况。随后,应用了 4 种不同的检测方法对这 4 张图像中的运动目标进行检测,结果如图 5 所示。




基于体素柱形的检测方法




基于改进 PointPillars 的检测方法



基于视觉与 2D 激光雷达的检测方法




所提方法
(a) 图像 1




基于体素柱形的检测方法



基于改进 PointPillars 的检测方法




基于视觉与 2D 激光雷达的检测方法




所提方法
(b) 图像 2





基于体素柱形的检测方法




基于改进 PointPillars 的检测方法




基于视觉与 2D 激光雷达的检测方法

所提方法
(c) 图像 3

基于体素柱形的检测方法



基于改进 PointPillars 的检测方法



基于视觉与 2D 激光雷达的检测方法


所提方法
(d) 图像 4

图 5 检测效果

通过图 5 的详细对比,可以清晰地观察到所提方法在应对交通视频图像中不同速度下运动目标检测时的显著优势。对于快速移动的目标(快速行驶的车辆),传统基于体素柱形的检测方法由于难以捕捉目标的动态变化,生成的检测图像常出现模糊或遗漏现象,导致检测精度下降。而改进后的 PointPillars 方法虽然有所提升,但在处理速度变化较快的目标时仍有不足。对于慢速或中等速度运动的目标,如行人或缓慢行驶的车辆,基于视觉与 2D 激光雷达的检测方法虽然能够较为准确地捕捉到目标轮廓,但在复杂交通背景下,其检测精度和稳定性仍有待提高,特别是在目标相互遮挡或背景干扰较强的情况下。相比之下,所提的深度帧差结合卷积神经网络(CNN)的方法展现出了对不同速度下运动目标检测的全面优势。该方法不仅通过帧差法有效捕捉了连续帧间的像素变化,还利用 CNN 强大的特征提取和学习能力,深入挖掘了运动目标在不同速度下的独特特征。这些特征不仅包含了目标的形状、大小等基本信息,还涵盖了目标的运动轨迹、速度变化等动态信息,从而使得模型能够更加精准地区分运动目标与背景,即使在目标速度发生显著变化时也能保持稳定的检测性能。

在 4 幅测试图像中,无论是快速穿越的车辆、缓步行走的行人,还是匀速行驶的车辆,所提方法均能够清晰、准确地检测出目标,并给出精确的边界框。这一结果表明,所提方法在应对不同速度下运动目标的检测任务时,具有更高的鲁棒性和准确性。

4 结论

针对激光雷达交通视频图像中运动目标检测的挑战,特别是针对目标速度变化导致的检测难题,创新性地融合了深度帧差法与卷积神经网络(CNN),提出了一种高效的运动目标检测方法。该方法首先利用帧差法有效捕获帧间像素的细微变化,作为运动信息的初步筛选。随后,深度卷积神经网络被引入以深度挖掘并精准提取这些变化中的关键目标特征,通过其强大的特征学习能力,不仅去除了冗余信息,还强化了目标识别能力。实验验证表明,该方法显著提升了运动目标检测的精度与鲁棒性,尤其在在不同速度目标检测上展现出卓越性能,为智能交通系统的发展开辟了新的技术视野,提供了更为精准和可靠的解决方案。

参考文献

- [1] 孙扬,唐大山. 激光雷达下车辆检测算法的研究[J]. 机械设计与制造,2023(12):129-132.
- [2] 杜延墨,沈三民,张炳玮. 基于结构相似度和鲁棒主成分分析的运动目标检测[J]. 激光杂志,2024,45(02):54-57.
- [3] 刘树伟,梁聪聪. 基于红外技术与激光雷达的新能源汽车无人驾驶障碍检测[J]. 应用激光,2022,42(09):97-104.
- [4] 栗文韬,徐成伟,张万鹏,等. 基于激光雷达+视频的城际铁路周界入侵监测报警技术研究[J]. 铁道运输与经济,2023,45(07):134-142.
- [5] 程鑫,王宏飞,周经美,等. 基于体素柱形的激光雷达点云车辆目标检测算法[J]. 中国公路学报,2023,36(03):247-260.
- [6] 陈德江,余文俊,高永彬. 基于改进 PointPillars 的激光雷达三维目标检测[J]. 激光与光电子学进展,2023,60(10):447-453.
- [7] 潘文波,李程,袁希文,等. 面向地铁场景的激光雷达目标检测研究[J]. 机车电传动,2022(02):89-96.
- [8] 张浩,左杭,刘宝华. 视觉与二维激光雷达的目标检测方法[J]. 电子测量与仪器学报,2022,36(03):79-86.
- [9] 唐立平,王窈,储根柏,等. 超快激光 X 射线单发照相的图像增强方法研究[J]. 中国激光,2023,50(22):132-139.
- [10] 晋帅,李焯鹏,杨凤,等. 伪激光点云增强的道路场景三维目标检测[J]. 中国图像图形学报,2023,28(11):3520-3535.
- [11] 邹锦阳,张雅婷,丁欣,等. 激光致声混凝土内部空洞检测[J]. 红外与激光工程,2023,52(01):134-143.
- [12] 秦庆国,许录平,孙学荣,等. 基于激光雷达的多帧联合目标跟踪系统[J]. 雷达科学与技术,2022,20(01):98-108+118.
- [13] 刘振宇,惠泽宇,郭旭,等. 基于滑动窗口优化的激光雷达惯性测量单元紧耦合同时定位与建图算法[J]. 科学技术与工程,2022,22(21):9167-9175.
- [14] 周志鹏,楼盈天,王升帆,等. 基于卡尔曼滤波的激光外差干涉位移测量误差补偿[J]. 光学精密工程,2024,32(03):357-365.
- [15] 焦嵩鸣,姚鑫,丁辉,等. 适应于环境空间变化的激光雷达 SLAM 建图方法[J]. 系统仿真学报,2023,35(08):1788-1798.
- [16] 牛国臣,王月阳,田一博. 改进密度聚类的激光雷达障碍物检测方法[J]. 北京航空航天大学学报,2023,49(10):2608-2616.
- [17] 张煌,何佳洲,王景石,等. 基于全景图像的无人艇激光雷达杂波滤除方法[J]. 光学学报,2022,42(18):74-84.
- [18] 陈文婷,罗文婷,李林,等. 基于 2D 与 3D 激光图像的轨道扣件状态智能检测[J]. 仪表技术与传感器,2022(11):88-95.